arqueología de la I.A. generativa_

Creación visual con estéticas revaloradas

Sesión 2
El zoológico de clases



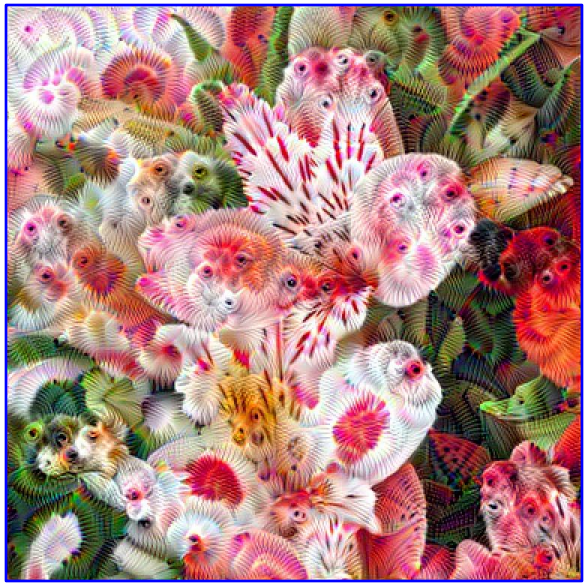
BigGAN · 50% jellyfish · 50% starfish

00

lo que vimos_

De reconocer a generar

sesión 1: la red que alucina_



Inception: una red entrenada para reconocer 1000 categorías de ImageNet

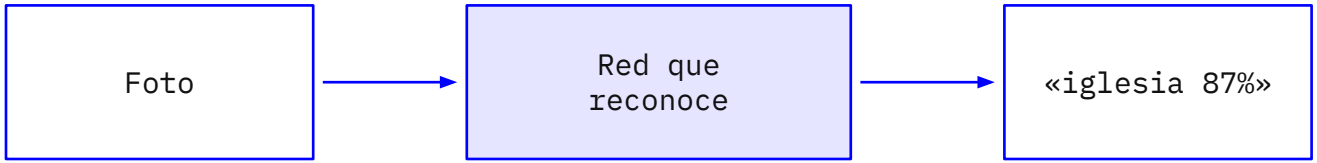
DeepDream: dejamos la red quieta y cambiamos la imagen para que la red vea más

Capas: las bajas sueñan texturas; las medias, ojos y animales

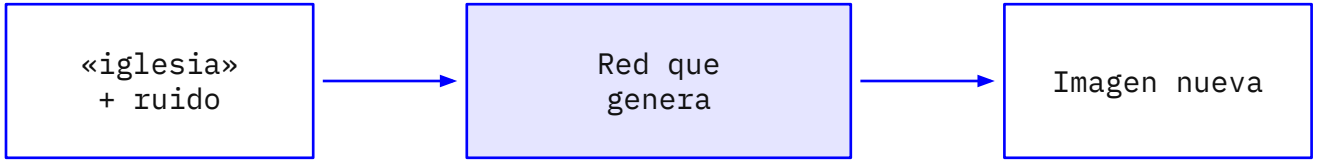
El sesgo: la red solo ve lo que le enseñaron; por eso, perros

de reconocer a generar_

Sesión 1 · Inception



Sesión 2 · BigGAN



Mismo ImageNet, dirección contraria. Antes la red decía qué veía; ahora fabrica lo que le pedimos.

el mapa_

1

DeepDream
2015 · La red que alucina

2

BigGAN
2018 · El zoológico de clases

hoy

3

Projected GAN
2021 · El espacio abstracto

4

FILM
2022 · Interpolación

Las sesiones 2 y 3 son GANs: hoy aprendemos cómo funcionan por dentro.

01

qué es una GAN_

Generative Adversarial Network

generar desde cero_

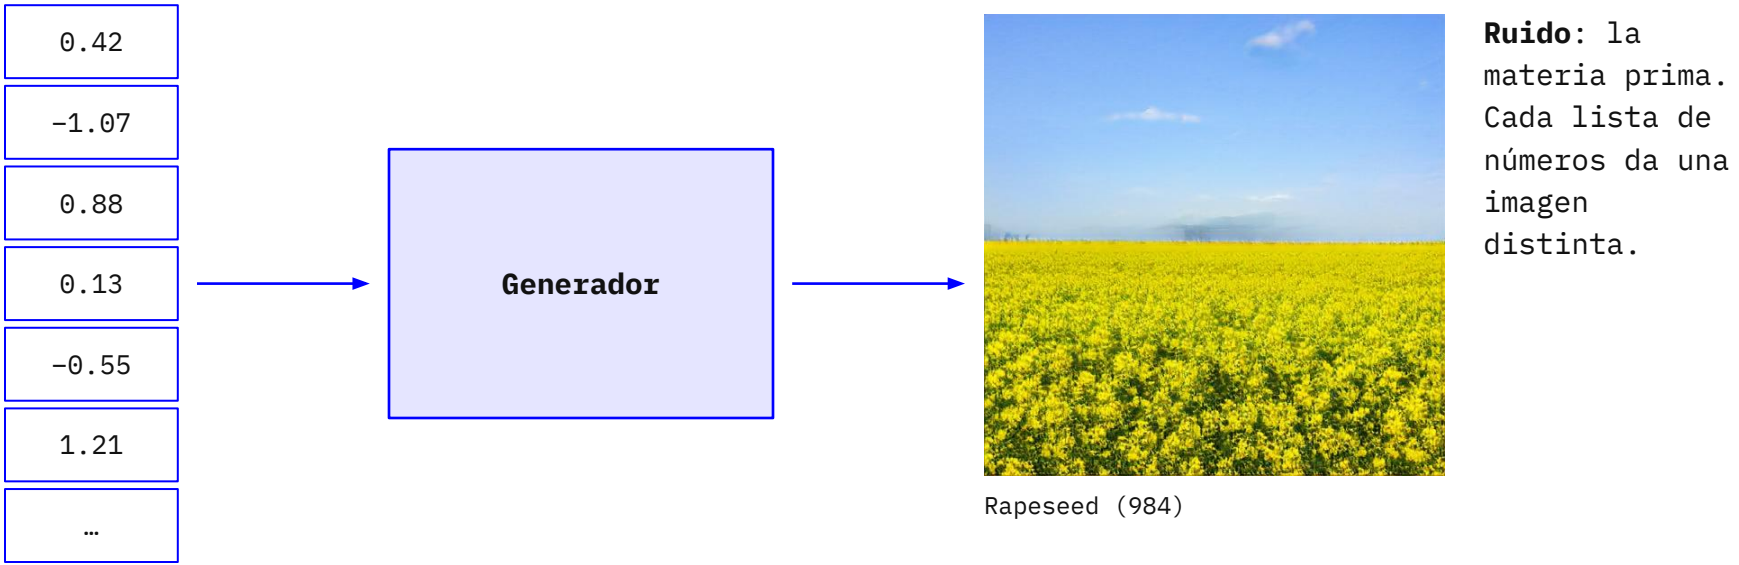
Un modelo generativo mira miles de imágenes y aprende **cómo suelen ser**: qué colores, formas y texturas aparecen juntas.

Después puede fabricar **imágenes nuevas** que podrían estar en ese conjunto, pero no están. No copia: inventa a partir de lo que aprendió.



Starfish (327) · semillas 42 a 45

de números a imagen_

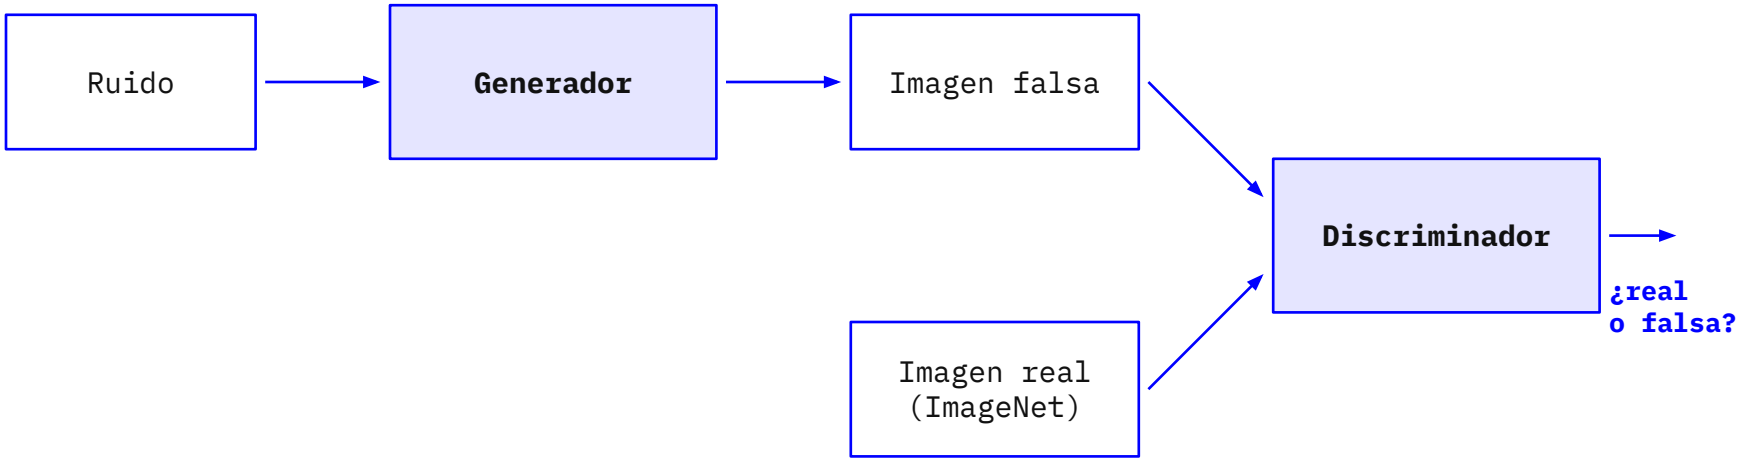


128 números
al azar

Rapeseed (984)

Ruido: la materia prima. Cada lista de números da una imagen distinta.

el juego_



Dos redes que se entrenan compitiendo. El generador fabrica imágenes; el discriminador recibe imágenes reales y falsas mezcladas y tiene que adivinar cuáles son cuáles.

el falsificador y el detective_

Generador
El falsificador

Pinta cuadros falsos. Al principio, manchas sin sentido. Con cada error descubierto, aprende qué lo delató.

Discriminador
El detective

Mira cuadros reales y falsos. Aprende a detectar las falsificaciones, y cada vez tiene que mirar con más detalle.

Por eso «adversaria»: cada una mejora intentando ganarle a la otra.

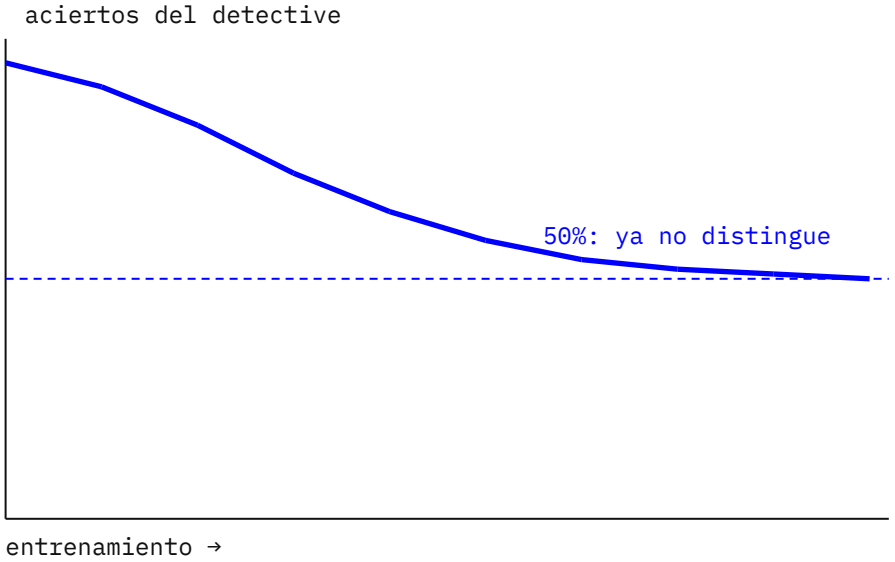
cómo aprenden_

1. El discriminador ve imágenes reales y falsas, y se corrige para separarlas mejor
2. Las imágenes del generador pasan por el discriminador, que da su veredicto
3. El error de ese veredicto vuelve hacia atrás hasta el generador (retropropagación)
4. El generador ajusta sus pesos para que la próxima vez el discriminador diga «real»
5. Repetir, por millones de imágenes

El generador nunca ve una imagen real. Aprende solo de lo que le dice el detective.

Es la misma retropropagación de la Sesión 1: un error que viaja hacia atrás y corrige los pesos.

el equilibrio_

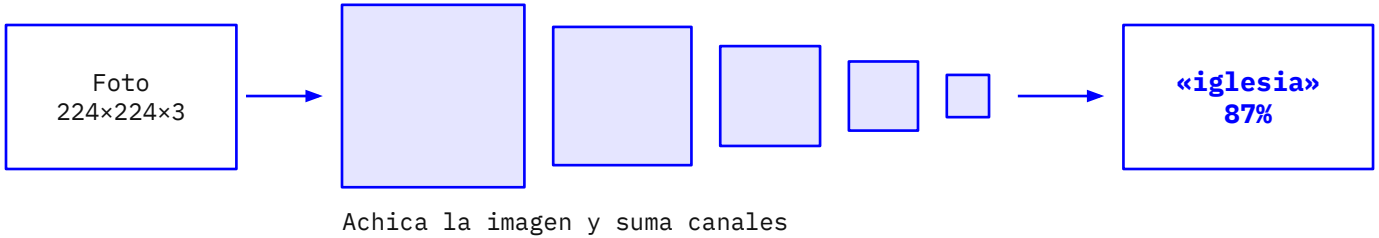


El ideal: el falsificador es tan bueno que el detective **acierta la mitad de las veces**, como tirar una moneda.

En la práctica es un equilibrio frágil. Un problema típico: el **colapso de modos**, cuando el generador descubre unas pocas imágenes que engañan bien y deja de variar.

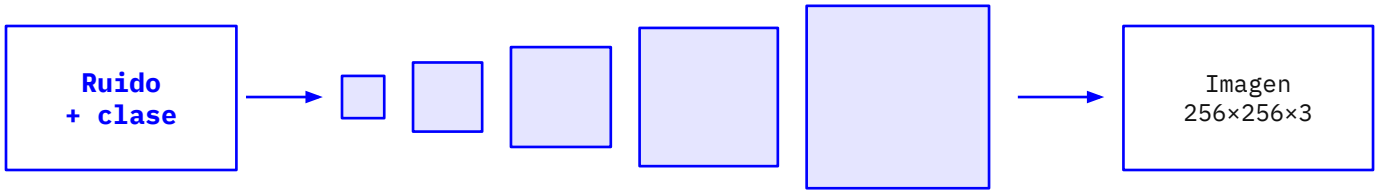
reconocer vs generar_

Sesión 1 · reconocer (Inception)



Achica la imagen y suma canales

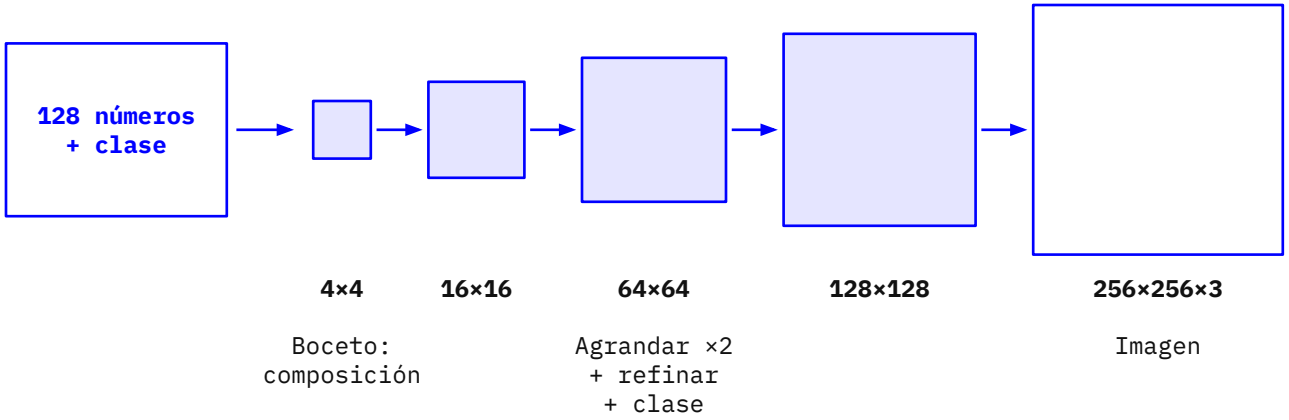
Sesión 2 · generar (BigGAN)



Agranda la imagen y quita canales

Dos redes distintas, en direcciones opuestas. El generador no tiene una parte que achique: empieza en el vector.

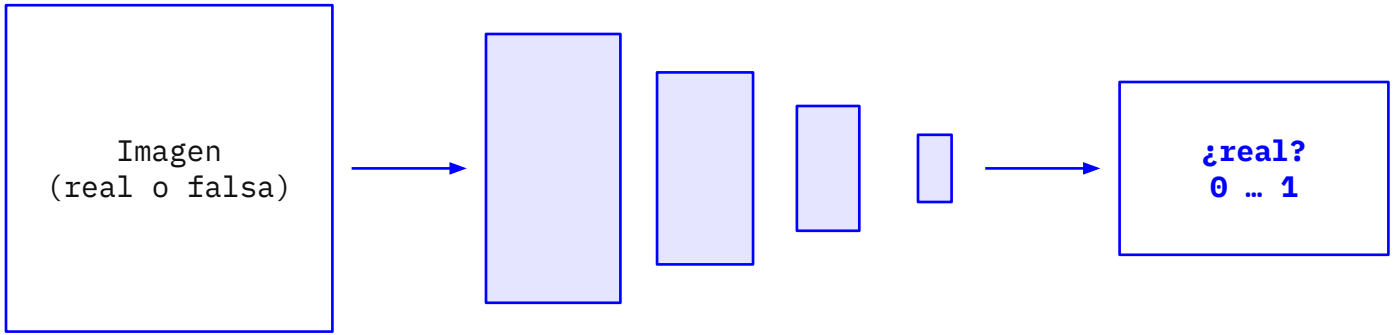
dentro del generador_



Primero el boceto, después el detalle. Las primeras capas deciden la composición y la forma; las últimas, la textura.

Al revés que en la Sesión 1: allá las capas bajas veían texturas y las altas, objetos. Y se parece a las octavas: primero lo grande, después lo fino.

dentro del discriminador_



En BigGAN el detective también sabe qué clase se pidió: no pregunta «¿es real?», sino «¿es una iglesia real?».

Es un clasificador, como Inception, pero con una sola pregunta: ¿real o falsa?

02

biggan_

DeepMind, 2018

2018: escalar_

2048

imágenes mira a la vez mientras aprende

512 × 512

tamaño máximo de las imágenes que genera (hay versiones de 128, 256 y 512)

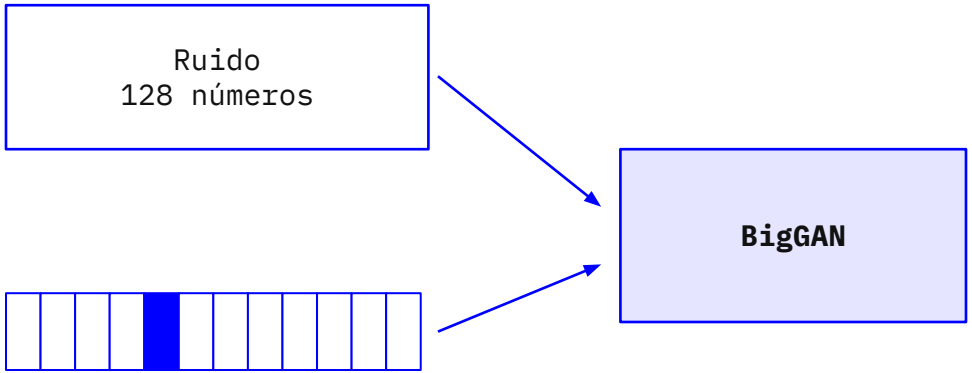
1000

clases de ImageNet

Big = más grande. Brock, Donahue y Simonyan tomaron las ideas que ya existían y las escalaron: redes más anchas, lotes enormes, mucho cómputo. El salto en calidad sorprendió a todo el campo.

Usamos BigGAN-deep, una variante más profunda presentada en el mismo artículo.

condicional por clase_



Clase: 1000 casillas, una encendida

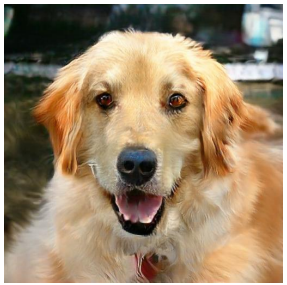
Dos perillas: el ruido decide **cómo** es la imagen (pose, encuadre, color); la clase decide **qué** es.

Las dos entradas se combinan en todas las capas del generador.

el zoológico, otra vez_



Chihuahua (151)



Golden Retriever (207)



Corgi (263)

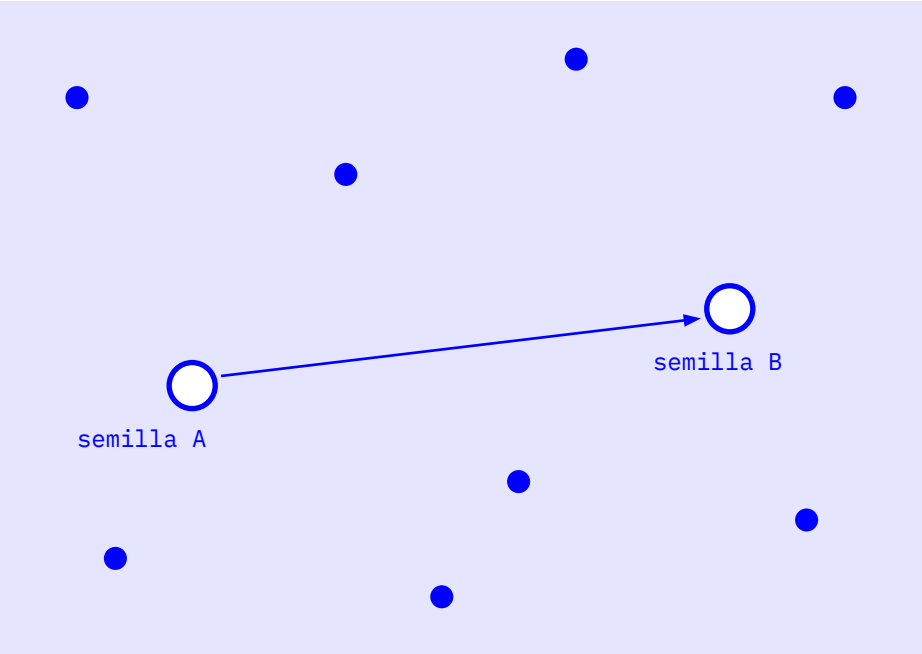


Pug (254)

Las mismas 1000 clases de la Sesión 1: unas **120 son razas de perro**.

La red que reconocía perros en todas partes y la red que fabrica perros aprendieron del mismo archivo. Cambia la máquina, no la mirada.

el espacio latente_



Cada lista de 128 números es **un punto** en un espacio enorme. Cada punto es una imagen.

Puntos cercanos, imágenes parecidas. Caminar de un punto a otro transforma la imagen de a poco.

(el dibujo tiene 2 dimensiones; el espacio real tiene 128)

semilla_

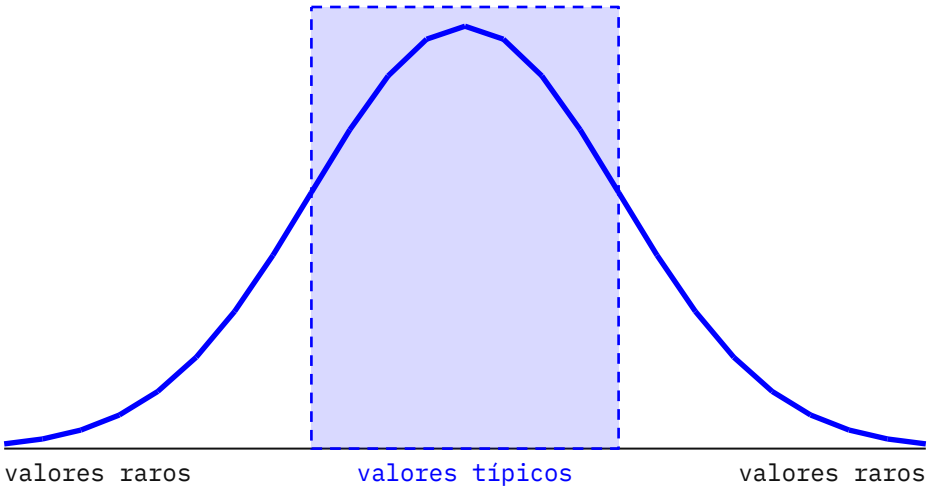


Hummingbird (94) · cuatro semillas

SEMILLA: un número que fija los 128 números al azar.

- Misma semilla + misma clase = misma imagen
- Otra semilla = otra pose, otro encuadre, otro color
- Anota las semillas que te gusten

truncación_



Los 128 números salen de una **campana**: la mayoría cerca de 0, pocos lejos. La red aprendió bien el centro y poco las colas.

La truncación los multiplica (va de casi 0 a 1):

1.5 × 0.4 = 0.6
1.5 × 1.0 = 1.5

Cerca de 0: todos los números se aprietan hacia el centro → típico, nítido, parecido.

Cerca de 1: toda la campana, con zonas que la red casi no vio → variado, raro, alucinado.

truncación: calidad vs variedad_



más típico, más nítido → **más raro, más variado**

Truncación baja: lo que la red cree que es «una medusa promedio». **Alta:** lo que está en los bordes de lo que aprendió. Ahí vive la alucinación.

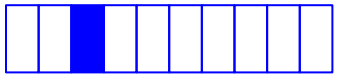
Jellyfish (107) · misma semilla

híbridos_

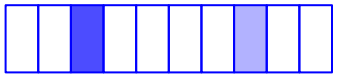


100% A · 0% B | 75% A · 25% B | 50% A · 50% B | 25% A · 75% B | 0% A · 100% B

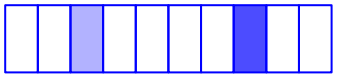
A = Jellyfish (107) · B = Starfish (327)



100% medusa



70% medusa · 30% estrella



30% medusa · 70% estrella

Mezclar clases crea criaturas que no existen en ningún dataset. No es un collage: la red no sabe que «no se puede».

interpolar_



Jellyfish (107) → Starfish (327)

Son los híbridos en secuencia: en vez de cinco mezclas, cientos. Cada frame es una proporción un poco distinta.

Mover la clase: la medusa se vuelve estrella

Mover el ruido: cambia la pose y el encuadre

Las dos a la vez: todo se transforma

Cada paso del camino es un frame del video.

03

el colab, paso a paso_

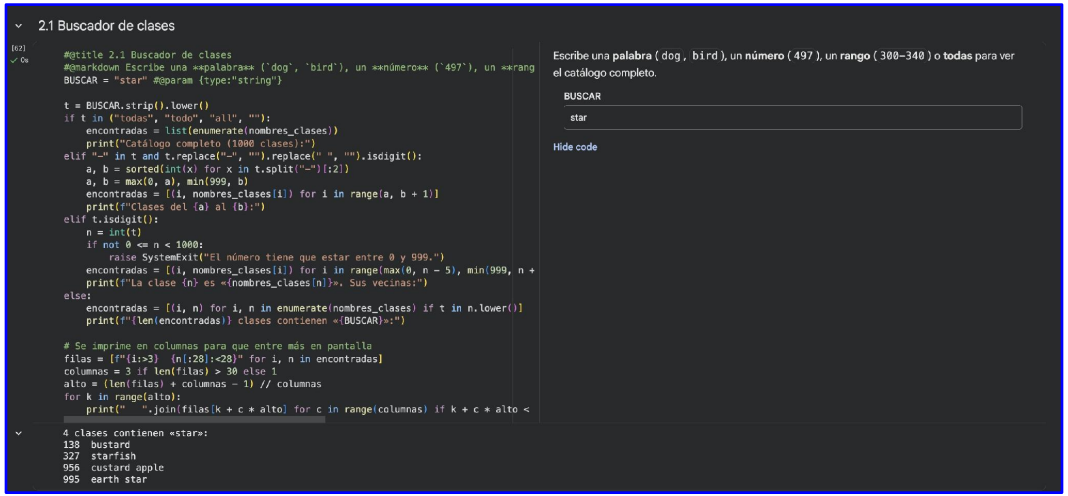
Qué hace cada perilla

el recorrido del notebook_

0 · 0.1	Preparar y conectar Drive
1	Cargar BigGAN (128 · 256 · 512)
2 · 2.1	Catálogo y buscador de clases
4 · 4.1	Imágenes y truncaciones
5	Híbridos
6.0 – 6.3	Videos
7	Descargar

Igual que en la Sesión 1: formularios a la derecha, ejecutar en orden, y todo se guarda en Taller_MUTAR/sesion2 de tu Drive.

clases_



Buscar «star» encuentra starfish… y también bustard, custard apple y earth star.

Por nombre: church, monarch butterfly

Por número: 497

Por parte: jelly → jellyfish

Por rango: 300-340

Todas: el catálogo completo

En inglés, como en ImageNet

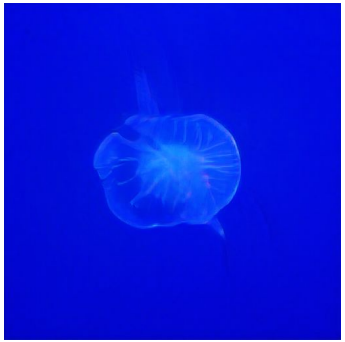
resolución_



128 × 128



256 × 256



512 × 512

Misma clase y semilla, tres medusas distintas: cada resolución es una red entrenada por separado.

Jellyfish (107) · las tres mostradas al mismo tamaño

128: rápido, para explorar

256: el equilibrio recomendado

512: máximo detalle, unas 4 veces más lento

AMPLIAR (×2, ×4) solo estira la imagen: sirve para pantallas grandes, pero no agrega detalle.

videos_

6.1 · Entre dos clases

- De A a B, con los híbridos en el camino
- SEMILLA_B: también cambia la forma
- SUAVIZADO · IDA_Y_VUELTA

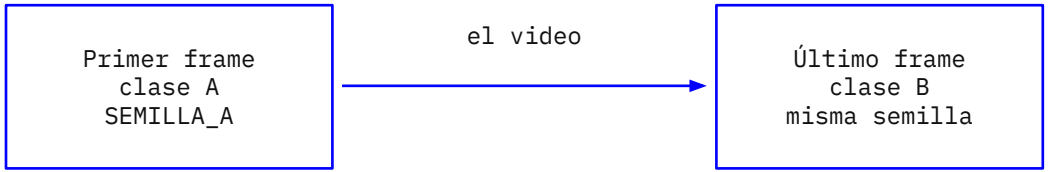
6.2 · Viaje largo

- Un recorrido por muchas clases
- SEGUNDOS_POR_TRAMO × clases = duración
- VOLVER_AL_INICIO: bucle perfecto

Duración × FPS = frames · 10 s a 256 px: menos de un minuto con GPU.

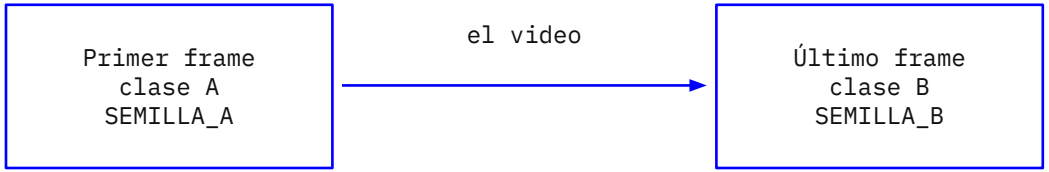
las dos semillas del video_

SEMILLA_B vacía (por defecto)



Cambia qué es. La pose se mantiene: la medusa se vuelve estrella «en el mismo lugar».

SEMILLA_B con otro número



Cambia qué es y cómo es. También se mueven la pose, el encuadre y el fondo.

Viaje largo (6.2): SEMILLA_VJ = un ruido para todo · SEMILLAS = una por clase

tablero de control_

Parámetro	Qué hace	Para probar
CLASE	Qué categoría generar	church · jellyfish · 497
SEMILLA	Fija el ruido: pose, encuadre	42 · 123 · 2024
TRUNCACION	Típico (bajo) o raro (alto)	0.2 · 0.5 · 1.0
RESOLUCION	Tamaño que genera BigGAN	128 · 256 · 512
CLASE_A / CLASE_B	Los extremos del híbrido	church / banana
DURACION_SEG	Largo del video	8 · 20 · 60
RECORRIDO	Clases del viaje largo	church, banana, volcano
AMPLIAR	Estira los frames	1 · 2

04

manos a la obra_

Práctica y conversación

antes de empezar_

1. Archivo → Guardar una copia en Drive
2. Entorno de ejecución → T4 GPU
3. Celda 0.1: conectar Drive
4. Ejecutar las celdas en orden

el ejercicio_

Explorar

Una clase, varias semillas y truncaciones

→ tu imagen favorita

Mezclar

Dos clases que no tengan nada que ver

→ tu híbrido

Viajar

Un video entre clases, o un viaje largo

→ tu video para la Sesión 4

Guarda tu imagen favorita y tu video: los vamos a usar en la Sesión 4.

para conversar_

? ¿Qué es un híbrido que no existe en ningún archivo? ¿Quién lo inventa: la red, el dataset o nosotrxs?

? Truncación baja = «la iglesia promedio». ¿Quién decide cómo es una iglesia típica?

? El generador nunca vio una foto real: aprendió a engañar. ¿Qué tipo de realismo es ese?

? Mismo ImageNet que la Sesión 1. ¿Qué mundos siguen afuera?

próxima sesión_

Projected GAN · 2021

El espacio abstracto: una GAN que no genera clases sino pura composición, color y textura. Sin iglesias ni perros.

- Guarda tu imagen favorita y tu video
- Están en tu Drive: Taller_MUTAR/sesion2

gracias_



Máquinas de Estados Infinitos

maquinasestadosinfinitos.net

IG @maquinas_estados_infinitos