arqueología de la I.A. generativa_



Creación visual con estéticas revaloradas

Sesión 3

El espacio abstracto

00

lo que vimos_

De las clases a la abstracción

sesión 2: el zoológico de clases_



GAN: un generador que fabrica y un discriminador que juzga

BigGAN: ruido + clase de ImageNet → imagen

Semilla: fija el ruido; misma semilla, misma imagen

Truncación: cerca de 0, típico; cerca de 1, alucinado

Híbridos e interpolación: mezclar clases y viajar entre ellas

el mapa_

1

DeepDream
2015 · La red que alucina

2

BigGAN
2018 · El zoológico de clases

3

Projected GAN
2021 · El espacio abstracto

hoy

4

FILM
2022 · Interpolación

Otra GAN, sin clases: habitaciones que no se pueden nombrar y criaturas que casi existen.

de biggan a projected gan_

	BigGAN (sesión 2)	Projected GAN (hoy)
Año	2018	2021
Aprendió de	1,2 millones de fotos (ImageNet)	3 millones de dormitorios · 833 Pokémon
Clases	1000	ninguna
Ruido	128 números	256 números
Truncación	sí	no
Tamaño	128 · 256 · 512 px	256 px (más con el lienzo expandido)
Entrenamiento	semanas, cientos de procesadores	horas

01

projected gan_

Un detective con lentes prestados

el problema_

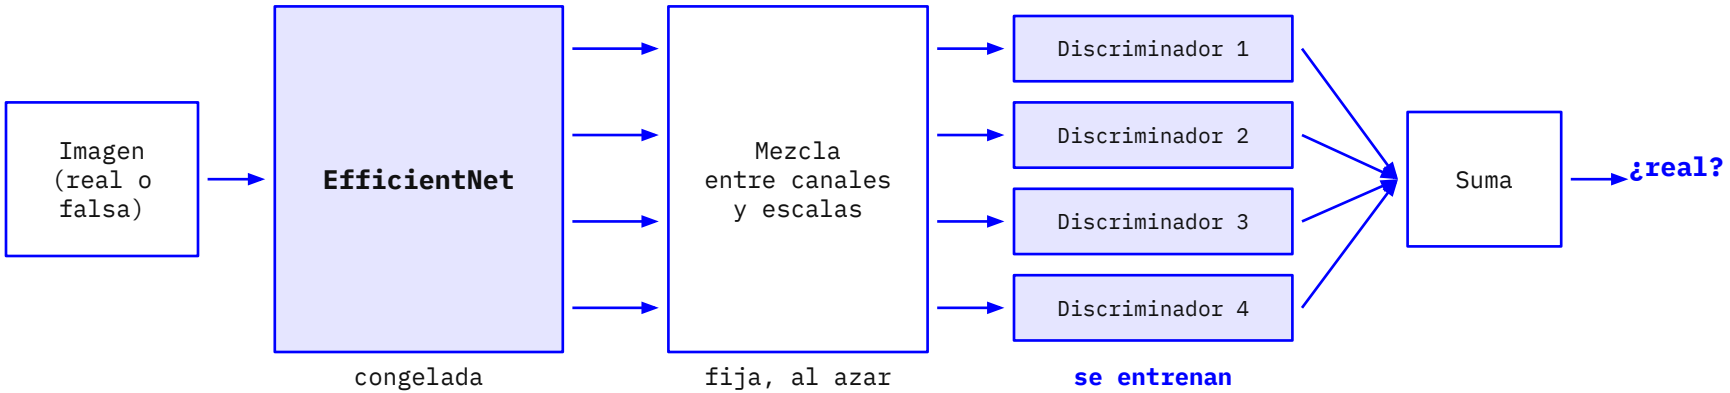
Al empezar el entrenamiento, el detective **no sabe mirar**: tiene que aprender qué es una textura, un borde o una forma, al mismo tiempo que el falsificador aprende a pintar.

- Entrenar es lento: días o semanas
- Es inestable: una red le gana a la otra
- Necesita muchísimas imágenes

Discriminador
empezando de cero

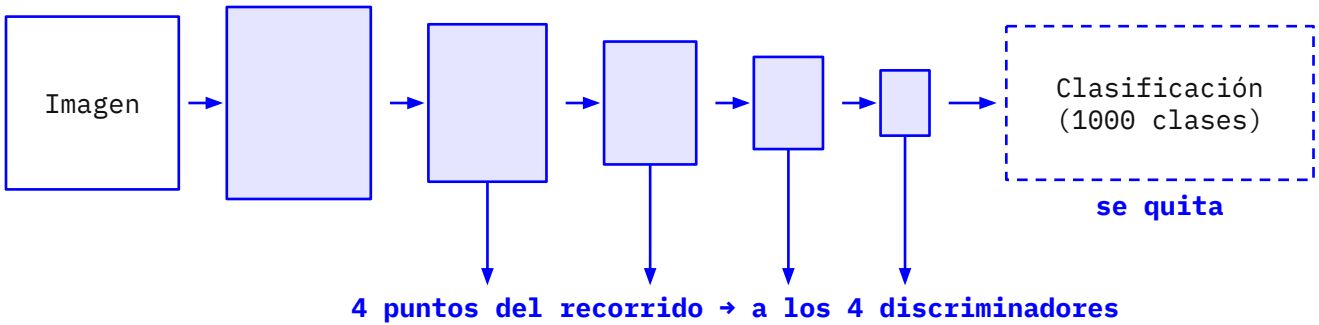
¿y si le prestamos una mirada que ya sabe ver?

un detective con lentes_



Projected: el detective no juzga la imagen, sino su proyección, lo que EfficientNet ve de ella. Mirar ya está resuelto; los cuatro discriminadores chicos solo aprenden a juzgar.

efficientnet_



Una red de clasificación, como Inception: convoluciones que van de bordes y texturas a partes y objetos. Entrenada con ImageNet.

Projected GAN no usa la respuesta final. Como DeepDream con los mixed: lo que importa son las activaciones de las capas intermedias.

más rápido, con menos_

40×

hasta 40 veces más rápido

5 días → <3 h

mismo resultado, mismo equipo

~1000

imágenes alcanzan para entrenar

Una mirada prestada acelera todo: el discriminador ya llega sabiendo ver, y el generador aprende mucho más rápido y con pocos datos.

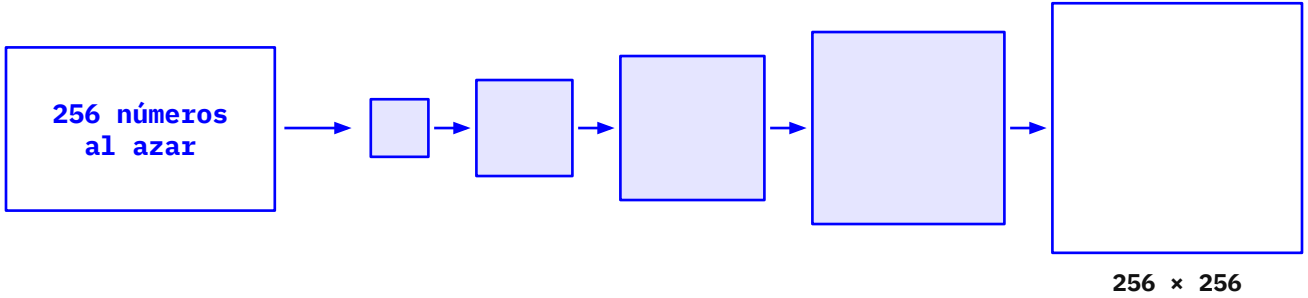
la mirada prestada_

EfficientNet fue entrenada con **ImageNet**: las mismas 1000 categorías de las sesiones 1 y 2.

Hoy generamos habitaciones y criaturas, sin clases. Pero el detective que decide qué «parece real» sigue mirando con **los ojos de ImageNet**.

La mirada no desaparece: se vuelve infraestructura.

fastgan: el generador_



Un generador liviano, pensado para aprender con muy pocas imágenes: de 100 a unas 1000.

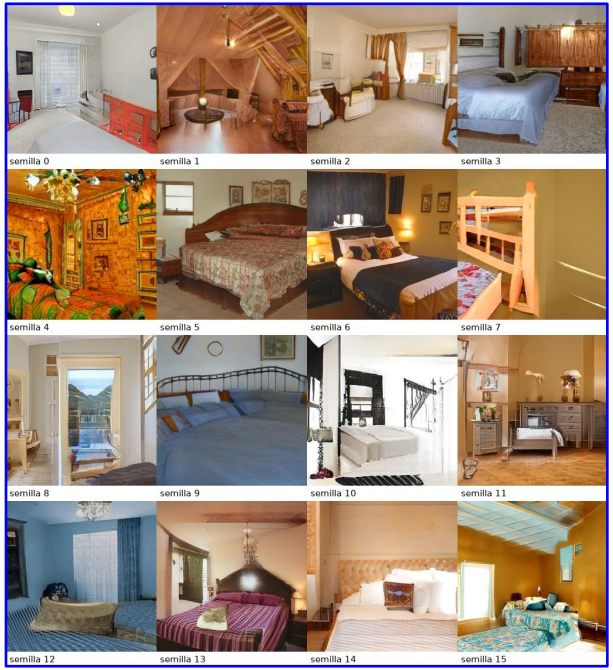
Misma idea que BigGAN: agrandar capa por capa. Pero más chico, y sin clases.

02

lugares y criaturas_

Dos mundos sin clases

habitaciones sin nombre_



Un dataset de **unos 3 millones de fotos de dormitorios** (LSUN).

La red aprende la **apariencia** de un cuarto: la luz, los colores, la perspectiva. Pero nadie le dijo nunca qué es una lámpara.

Parece una habitación, hasta que intentas nombrar lo que hay en ella.

criaturas que casi existen_

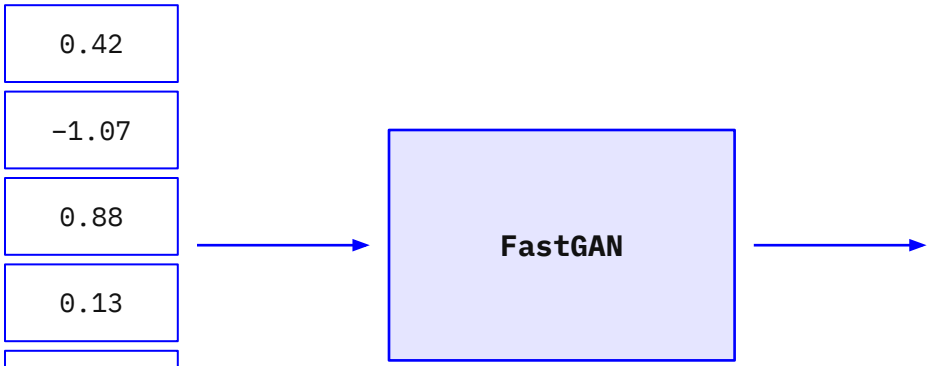


833 ilustraciones distintas de Pokémon, sobre fondo blanco.

Con tan pocos ejemplos, la red genera seres que **casi** son Pokémon: patas, ojos y colores que no terminan de ser nadie.

Millones de cuartos o unos cientos de criaturas: la cantidad de datos también es estética.

solo ruido_



256 números
al azar

Sin clases. No le pedimos «cama» ni «Pikachu»: solo la semilla decide qué sale.

Cada semilla es un punto en un espacio de 256 dimensiones.

En nuestro Colab hay unos 4.300 millones de semillas, pero entre ellas hay infinitos puntos. Y semillas seguidas no son vecinas: para encontrar imágenes parecidas, usa el vecindario.

¿y la truncación?_

Estos modelos no la tienen. FastGAN normaliza el ruido apenas entra: lo lleva siempre a la misma escala.

0.4 × ruido → normalizar → igual
1.0 × ruido → normalizar → igual

Achicar los números, como hacía BigGAN, no cambia nada.

No todas las GANs tienen las mismas perillas.

Hoy vamos a inventar las nuestras.

el vecindario_



Distancia 0.2: variaciones



Distancia 0.8: otras criaturas

Semilla 7 al centro,
ocho vecinas alrededor.

Qué tanto me alejo de lo conocido: la misma pregunta de la truncación, alrededor de un punto que tú eliges.

viajar entre semillas_



Una habitación se convierte en otra. La cama se corre, la ventana cambia de lugar, la luz se mueve.

6.1: de una semilla a otra

6.2: un viaje por muchas semillas, en bucle

FastGAN genera cientos de imágenes por segundo: un minuto de video sale en segundos.

otros mundos_

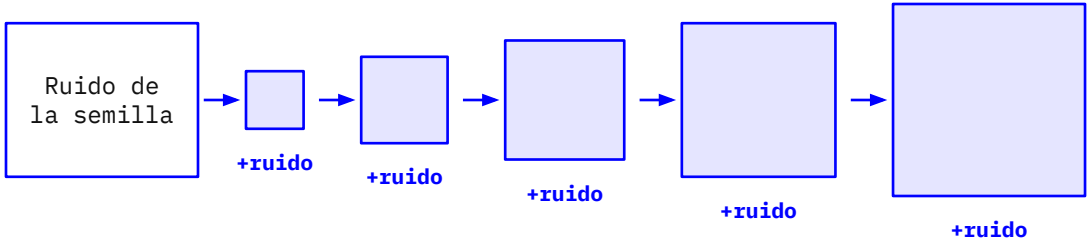
Modelo	Aprendió de
bedroom	un dataset de unos 3 millones de fotos de dormitorios (LSUN)
pokemon	833 ilustraciones de Pokémon
church · cityscapes	fotos de iglesias · calles desde un auto
art_painting	unas 1000 pinturas de WikiArt
landscape · flowers	fotos de paisajes · de flores
clevr	escenas 3D sintéticas de objetos simples
ffhq	retratos de rostros

03

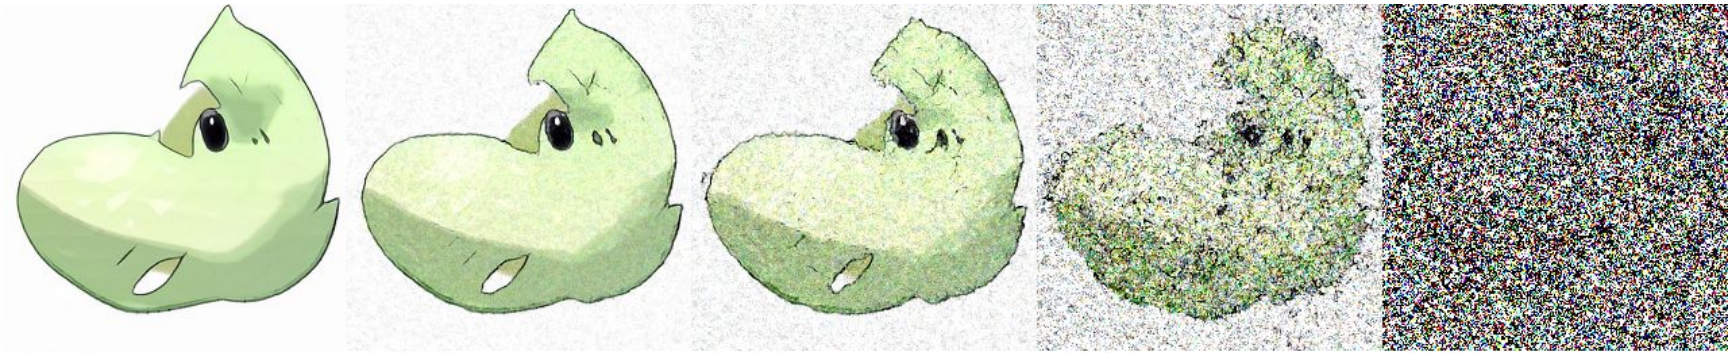
experimentos_

Inventar perillas

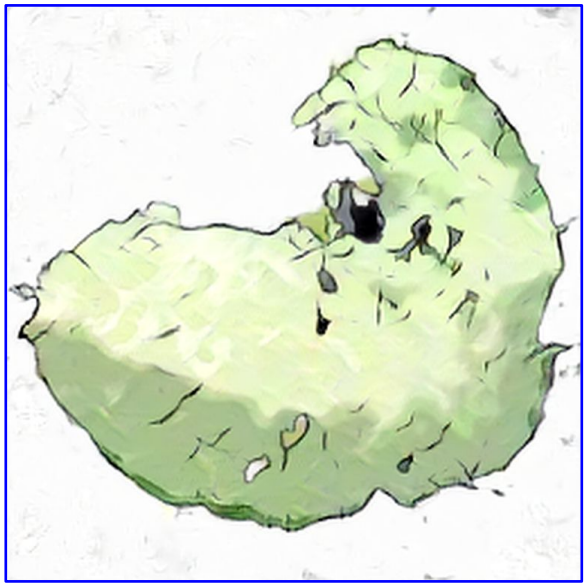
disolver_



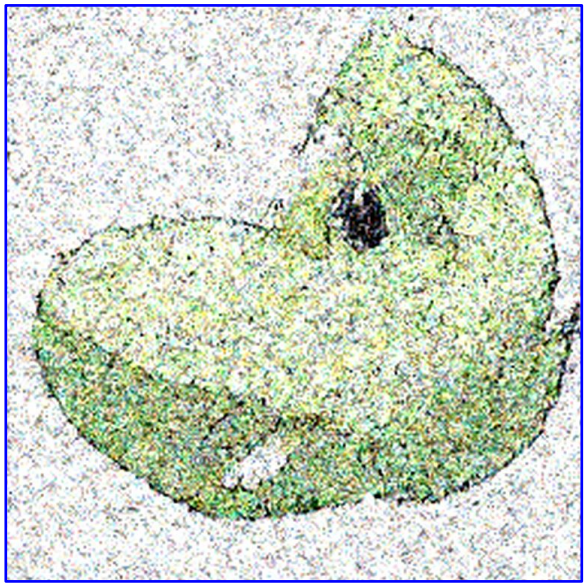
Le metemos ruido adentro, en cada capa, mientras la imagen se construye. NIVEL dice cuánto.



estructura o textura_



Capas chicas: se deforma

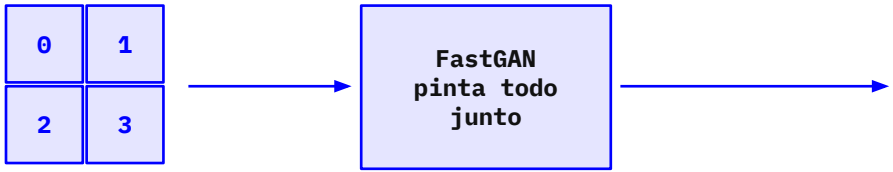


Capas grandes: se vuelve grano

Como en la Sesión 1: las capas chicas deciden la forma; las grandes, el detalle.

Ahora lo vemos desde el lado del que pinta.

lienzo expandido_



4 semillas
(4 × 4 cada una)

Las habitaciones se continúan: una cama se vuelve pared, aparece una ventana donde no debería.

Una arquitectura que no cierra.



bedroom · 2 × 2 semillas · 512 × 512 px

en movimiento_



6.3 · disolverse



6.4 · habitaciones infinitas

04

el colab, paso a paso_

Qué hace cada perilla

el recorrido del notebook_

0 · 0.1	Preparar y conectar Drive
1	Cargar el modelo (bedroom)
2	Motor de generación
3 · 3.1	Explorar semillas · una en grande
4	Vecindario (pokemon)
5.1	Disolver
5.2	Lienzo expandido
6.0 – 6.5	Videos
7	Descargar

Cada sección tiene su propio menú de modelo. Los modelos que ya se cargaron quedan en memoria. Todo se guarda en Taller_MUTAR/sesion3 de tu Drive.

tablero de control_

Parámetro	Qué hace	Para probar
MODELO	Qué mundo explorar	bedroom · pokemon
DESDE / CANTIDAD	Qué semillas mirar	0 / 16 · 500 / 32
SEMILLA	Fija el ruido	7 · 31 · 102
DISTANCIA	Cuánto alejarse en el vecindario	0.2 · 0.5 · 0.8
NIVEL	Cuánto disolver	0.25 · 0.5 · 1
CAPAS	Dónde disolver	chicas · grandes · todas
COLUMNAS × FILAS	Tamaño del lienzo expandido	3 × 2 · 6 × 1
SEMILLA_A / B	Extremos del video	0 / 31
AMPLIAR	Estira los frames	1 · 2 · 4

05

manos a la obra_

Práctica y conversación

antes de empezar_

1. Archivo → Guardar una copia en Drive
2. Entorno de ejecución → T4 GPU
3. Celda 0.1: conectar Drive
4. Ejecutar las celdas en orden

el ejercicio_

Nombrar

Recorrer habitaciones e intentar nombrar lo que hay

→ tus habitaciones favoritas

Disolver

Una criatura, en capas chicas y grandes

→ dónde se rompe la forma

Expandir

Un lienzo grande, quieto o en video

→ tu video para la Sesión 4

Guarda tus imágenes favoritas y un video: los vamos a usar en la Sesión 4.

para conversar_

? La red aprendió la apariencia de un cuarto sin los nombres de las cosas. ¿Qué significa «entender» una imagen?

? Pokémon: una franquicia comercial usada como dataset. ¿De quién son estas criaturas?

? El detective mira con los ojos de ImageNet. ¿Qué significa que una imagen «parezca real»?

? Sin truncación, inventamos perillas: disolver, expandir. ¿Dónde está la decisión artística?

próxima sesión_

FILM · 2022

Interpolación de frames: una red que inventa las imágenes intermedias entre dos fotos. Vamos a unir lo que hicimos en las tres sesiones en un solo video.

- Junta tus imágenes favoritas de las sesiones 1, 2 y 3
- Están en tu Drive: Taller_MUTAR

gracias_



Máquinas de Estados Infinitos

maquinasestadosinfinitos.net

IG @maquinas_estados_infinitos